

Analyse et prédiction du volume du SPY

Nicola-Henri Benassis, Victor Helpiquet

8 mars 2026

Table des matières

1	Introduction	2
2	Données et prétraitement	2
2.1	Description de la source	2
2.2	Prétraitement et mise en forme	2
3	Analyse descriptive	3
3.1	Étude des valeurs extrêmes	3
3.2	Étude de la saisonnalité	4
3.3	Étude de la stationnarité	5
4	Identification du processus	5
5	Simulation de prévision	6
5.1	Prévisions sur l'échantillon test	6
5.2	Modèles utilisés	6
5.3	Comparaison des modèles	6
5.3.1	Critère de comparaison	6
5.3.2	Modèle ingénu	6
5.3.3	Lissage exponentiel	7
5.3.4	ARIMA	8
5.3.5	Prophet	8
5.3.6	SARIMAX	9
5.4	Conclusion sur les différents modèles	10
6	Conclusion	10
6.1	Bilan des résultats obtenus	10

1 Introduction

Le volume échangé est un indicateur crucial de la liquidité, du régime de marché et du stress que ces derniers rencontrent. L'étude de son évolution permet d'obtenir des informations précieuses sur les habitudes et les visions des investisseurs, qu'ils soient institutionnels ou non. Dans ce projet, nous étudierons la série temporelle du volume de l'ETF SPDR S&P 500 ETF Trust (ticker : SPY), l'un des instruments financiers les plus liquides au monde, répliquant l'indice S&P 500. Cet indice bien que limité aux 500 plus grosses entreprises sur le marché américain permet tout de même d'obtenir une vision globale grâce à son rôle incontesté dans le rééquilibrage des fonds indiciels et son utilisation quasi-systématique par les investisseurs retails en tant qu'investissement diversifié.

2 Données et prétraitement

2.1 Description de la source

Les données utilisées proviennent de Yahoo Finance via l'API Python `yfinance`. Nous obtenons des séries temporelles de type OHLCV (Open, High, Low, Close, Volume). Ces données sont prétraitées, elles prennent en compte les dividendes, les fusions-acquisition et la nouvelle émission de parts, cela permet d'avoir une continuité dans les données étudiées. Par exemple, face à une division des parts, cela permet d'éviter une multiplication soudaine du volume par 2. Bien que l'étude intra-journalière du SPY s'avèrerait intéressante, notamment avec sa forme en "U" liée aux fortes activités d'ouverture et de fermeture des marchés ainsi qu'à son faible niveau lors de la pause du midi ; suite au nombre de pages limité de ce rapport, nous nous restreindrons à l'étude des données journalières du SPY.

2.2 Prétraitement et mise en forme

Une fois les données téléchargées au format `.csv`, nous avons modifiés les en-têtes pour permettre de les traiter comme une `DataFrame` pandas. Nous avons ensuite représenté la Série temporelle des volumes comme on peut l'observer figure 1 et nous nous sommes restreint aux valeurs après 2005, période où le SPY a fini sa croissance en popularité et s'est imposé comme acteur central des fonds indiciels. Ainsi, le volume à partir de cette période ne possède plus de tendance liée à un gain en popularité de cet ETF.





FIGURE 1 – Volume de parts du SPY échangées chaque jour à partir de 2005


3 Analyse descriptive

3.1 Étude des valeurs extrêmes

Dans un premier temps, nous remarquons à l'aide de la figure 2.a et 2.b le fort nombre de valeur extrêmes. Lorsque nous regardons où se situent ces valeurs (figure 3), nous remarquons qu'elles représentent les périodes de crise. En effet, la crise des subprimes de 2008 est marquée par plusieurs jours de fort volume ; la crise Covid aussi et même les annonces des taxes douanières de Trump en 2025. D'autres évènements sont aussi reconnaissable et une brève recherche sur internet permet de les identifier.



(a) Diagramme en boîte du volume de parts du SPY échangées



(b) Distribution du volume de parts du SPY échangées

FIGURE 2 – Observation de la répartition des valeurs du volume du SPY






FIGURE 3 – Jours où le volume échangé est deux fois supérieur à la moyenne annuelle

Comme le volume est toujours strictement positif, nous allons donc composer la série par le logarithme, cela a pour effet de limiter les valeurs extrêmes, notons aussi que cela transforme

une modélisation multiplicative en modélisation additive. D'après la figure 4.a et 4.b, on observe une nette amélioration de la dispersion des valeurs.



(a) Diagramme en boîte du log-volume des parts du SPY échantonnées




(b) Distribution du log-volume des parts du SPY échangées


FIGURE 4 – Observation de la répartition des valeurs du volume du SPY

3.2 Étude de la saisonnalité

Une fois l'effet des crises mitigé, nous pouvons poursuivre notre études sur la saisonnalité des marchés. D'après la figure 5.a, nous remarquons une périodicité hebdomadaire, en effet, le volume augmente tout au long de la semaine et atteint systématiquement un pic le vendredi. Ceci s'explique par le fait que les options expirent le vendredi et que beaucoup de fonds se rééquilibrent avant le week-end. D'après la figure 5.b on remarque un paterne mensuel remarquable : les mois de mars, juin et octobre forment des pics, ces derniers sont dus aux annonces trimestrielles des entreprises et aux rééquilibrages trimestriels. Les mois estivaux juillet et aout forment un creux preuve de l'activité réduite dans cette période. Le mois de décembre est confronté d'une part à une période festive qui mène à une activité moindre et d'autres part aux rapport annuels des entreprises augmentant le volume échangé.



(a) Moyenne des log-volumes échangés en fonction du jour de la semaine




(b) Moyenne des log-volumes échangés en fonction du mois de l'année

FIGURE 5 – Observation de la saisonnalité hebdomadaires et annuelle du log-volume du SPY


3.3 Étude de la stationnarité

Pour étudier la stationnarité de la série temporelle, nous observons ses ACF et PACF. D'après la figure 6.a, l'ACF décroît lentement vers un plateau d'une valeur de 0.6.

Afin d'obtenir une série stationnaire, cette observation nous pousse à différencier la série. Une fois cette opération réalisée, nous réobservons les ACF et PACF et nous remarquons que, d'après la figure 6.b, toutes deux passent en dessous d'un seuil significatif après 2 lags. Nous pouvons donc supposer la nouvelle série comme stationnaire.



(a) ACF et PACF du log-volume



(b) ACF et PACF du log-volume différencié

FIGURE 6 – Observation de la répartition des valeurs du volume du SPY

4 Identification du processus

Afin d'identifier notre processus, on analyse d'abord les ACF/PACF du log-volume. On observe alors une tendance. On a alors différencié notre processus, et nous avons à nouveau observé

nos ACF/PACF. On a clairement distingué une saisonnalité d'ordre 5, ce qui est normal car une semaine de travail dure 5 jours. On identifie alors notre processus en le désaisonnalisant : après 6 lags les valeurs de l'ACF sont négligeables. Quant à la PACF, son comportement n'est pas clair. On suppose alors un modèle MA(6). Afin de vérifier les résultats de notre analyse, on a utilisé le critère de sélection BIC, qui nous a permis de vérifier l'ordre de notre processus moyenne mobile. Le processus est donc un MA(6) stationnaire avec une saisonnalité d'ordre 5.




FIGURE 7 – ACF et PACF du log-volume différencié et désaisonné

5 Simulation de prévision

5.1 Prévisions sur l'échantillon test

. Afin de faire des tests de prévision, nous avons divisé nos données en deux séries temporelles. Notre série d'entraînement s'étale de 2021 à fin 2024, et nous avons choisi de faire nos test sur la période de 2025 à l'heure actuelle. Nous avons fait aussi d'autres essais avec une période de test plus courte (1 jour, 5 jours et 1 mois), mais les résultats étaient moins concluants.

5.2 Modèles utilisés

Afin de faire nos prévisions sur la période de test, nous avons entre autre essayé les principaux modèles vus en cours. Nous avons commencé par un modèle ingénu, puis nous avons testés les lissages exponentiels. Ensuite nous avons utilisé un modèle automatique développé par Meta : prophet. Finalement nous avons utilisé SARIMAX pour nos prévisions.

5.3 Comparaison des modèles

5.3.1 Critère de comparaison

Comme critère de comparaison et d'optimisation de nos modèles, nous avons choisi le RMSE (Root Mean Square Error), qui est le critère de comparaison le plus commun en régression. Ce critère implique pour les modèles de prévision une aversion à s'éloigner de la moyenne, ce que nous allons observer sur les résultats.

5.3.2 Modèle ingénu

Le modèle ingénu est un modèle constant qui prend la dernière valeur des données d'apprentissage. On obtient avec ce modèle une erreur : $RMSE=0.344$






FIGURE 8 – Prédications avec modèle ingenu

5.3.3 Lissage exponentiel

Comme nous avons vu précédemment, notre processus est stationnaire. Nous avons donc en premier lieu utilisé la méthode de Holt-simple (lissage exponentiel double) permettant de prédire la tendance sur nos données tests. Comme la popularité du S&P 500 est maintenant plutôt stable, on s'attend à ce que la tendance du volume prédit ait un coefficient directeur presque nul. Les résultats (figure 9.a) sont conformes à l'intuition, et le coefficient directeur est légèrement négatif. Afin d'ajouter une composante saisonnière et aléatoire à notre prédiction, on utilise ensuite le lissage de Holt-Winters. Ce lissage est notamment efficace pour les processus sensibles à des breaks. Ici les résultats obtenus ne sont pas très concluants (figure 9.b). Si la saisonnalité du processus est détectée, les pics de variations de celui-ci le sont beaucoup moins. Cette incapacité à prédire correctement le processus provient du caractère exogène de celui-ci. En effet bien que le volume soit de moyenne plutôt stable, il subit de nombreuses variations aléatoires et incontrôlées à chaque instant, ce qui complique sa prédiction. Avec ces modèles on obtient les erreurs : Holt-linear RMSE : 0.388 et Holt-Winters RMSE : 0.390



(a) Holt-simple



(b) Holt-Winters

FIGURE 9 – Prédiction grâce aux modèles exponentiels

5.3.4 ARIMA

En essayant de prédire l'évolution du log-volume en utilisant un modèle ARIMA, nous obtenons, la figure 10. Avec ce modèle, nous remarquons que la présence d'oscillations saisonnières de période 5 jours liées à la saisonnalité hebdomadaire s'estompe pour laisser place à une tendance linéaire. Ceci provient du fait que cherchant à minimiser l'erreur quadratique, le modèle va chercher à éviter de se tromper de direction dans les oscillations du volume et préférer rester le plus proche de la moyenne possible. On obtient $RMSE=0.363$.




FIGURE 10 – Prédiction avec ARIMA

5.3.5 Prophet

On remarque dans la figure 11 que le modèle Prophet marque d'avantage la saisonnalité hebdomadaire avec des pics quasiment invariants chaque semaine. De plus, il cherche aussi à répliquer la saisonnalité mensuelle comme on peut le voir avec les fortes augmentations autour des rapports

trimestriels. Cependant, il semblerait qu'il ait des difficultés à reconnaître la valeur moyenne autour de laquelle se pattern aurait du être reproduit. L'erreur obtenue est $RMSE=0.667$.






FIGURE 11 – Prédictions avec le modèle prophet

5.3.6 SARIMAX

La comparaison entre les figures 12.a et 12.b révèle que grande partie des variations du volume du SPY sont dues à des facteurs exogènes, ici les données utilisées sont celles obtenues à partir des OHLCV du SPY. Ainsi, la figure 12.b prouve que à partir de ces données, bien qu'avec un certain retard on arrive à se rendre compte de phénomènes de crise comme l'annonce des taxes douanières. Pour le SARIMA l'erreur vaut $RMSE=0.340$ tandis que pour un SARIMAX avec variables exogènes on a $RMSE=0.339$.



(a) SARIMA



(b) SARIMAX avec variables exogènes

FIGURE 12 – Prédictions avec le modèle SARIMAX

5.4 Conclusion sur les différents modèles

Grâce aux courbes obtenues et au critère d'erreur RMSE, on observe que la prévision de notre série temporelle s'avère difficile. Bien que nos RMSE soient proches de 0.35 (sauf Prophet), l'allure des courbes montrent que certains modèles permettent une meilleure prédiction. En l'occurrence, le modèle SARIMAX avec variables exogènes (RMSE=0.339) est celui minimisant le RMSE et permettant d'avoir la meilleure prédiction, ce qui montre l'importance des variables exogènes en finance.

6 Conclusion

6.1 Bilan des résultats obtenus

Notre projet portant sur l'analyse et la prédiction du volume de l'ETF SPDR S&P 500 nous a permis de mettre en pratique les concepts de séries temporelles étudiés en cours. Nous avons tout d'abord étudié les propriétés statistiques de cette série et relié son comportement à certaines pratiques financières courantes, telles que le rééquilibrage périodique des fonds indiciels. Cette analyse nous a permis d'identifier différentes dynamiques de marché, caractérisées par des périodes d'activité intense lors des crises financières et des périodes d'activité plus faible, notamment lors des périodes festives.

Par ailleurs, nos résultats suggèrent que le volume du SPY est fortement influencé par des facteurs exogènes, tels que le contexte macroéconomique, les événements géopolitiques ou encore la diffusion d'informations sur les marchés. Ces éléments ne sont pas directement capturés par les modèles de séries temporelles étudiés en cours. Ainsi, bien que certains modèles puissent reproduire certaines dépendances temporelles ou saisonnalités du volume, ils restent limités dans leur capacité à anticiper les variations importantes liées à des chocs informationnels. Cela explique les performances de prédiction relativement modestes obtenues, y compris avec des modèles plus flexibles comme Prophet.